

**PREDIKSI KEPERIBADIAN BERBASIS VIDEO
MENGUNAKAN TRANSFER LEARNING MODEL DEEPID**

PROPOSAL TUGAS AKHIR



OLEH

HANDIKA DIO PRADANA

NIM 21091397021

**UNIVERSITAS NEGERI SURABAYA
FAKULTAS VOKASI
PROGRAM STUDI D4 MANAJEMEN INFORMATIKA
2024**

**PREDIKSI KEPERIBADIAN BERBASIS VIDEO
MENGUNAKAN TRANSFER LEARNING MODEL DEEPID**

TUGAS AKHIR

Diajukan kepada Universitas Negeri Surabaya
untuk memenuhi persyaratan penyelesaian
program sarjana terapan

Oleh :

Handika Dio Pradana

21091397021

**PROGRAM STUDI D4 MANAJEMEN INFORMATIKA
FAKULTAS VOKASI
UNIVERSITAS NEGERI SURABAYA**

2024

II

HALAMAN PERSETUJUAN



KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET DAN TEKNOLOGI
UNIVERSITAS NEGERI SURABAYA
VOKASI

Kampus Utara Widen dan Kutarang
Surabaya 60231
T: +6231-4250000, +6231-4270458
F: +6231-4270458

LEMBAR PERSETUJUAN PENILAIAN PROPOSAL TUGAS AKHIR

Yang bertanda tangan di bawah ini

NIP : 198211022008121001
Nama : Salamin Rohman Nudin, S.Kom., M.Kom.

adalah Dosen Pembimbing dari mahasiswa
NIM : 21091397021

Nama : HANDIKA DIO PRADANA

Angkatan : 2021

Fakultas : VOKASI

Prodi : D4 Manajemen Informatika

dengan ini menyetujui bahwa artikel dengan judul di bawah ini untuk dinilai

Judul : PREDIKSI KEPRIHADIAN BERBASIS VIDEO MENGGUNAKAN TRANSFER LEARNING MODEL
Artikel : DEEPID

Demikian permohonan ini. Atas kerja sama yang baik, saya sampaikan terima kasih.

Surabaya, 11 November 2024
Dosen Pembimbing

Salamin Rohman Nudin, S.Kom., M.Kom.
NIP 198211022008121001

ABSTRAK

PREDIKSI KEPRIBADIAN BERBASIS VIDEO MENGUNAKAN TRANSFER LEARNING MODEL DEEPID

Nama : Handika Dio Pradana
NIM : 21091397021
Program Studi : D4 Manajemen Informatika
Fakultas : Vokasi
Nama Lembaga : Universitas Negeri Surabaya
Pembimbing : Salamun Rohman Nudin, S.Kom., M..Kom.

Penelitian ini mengembangkan sistem prediksi kepribadian berbasis teori *Big Five Personality* dengan menggunakan metode transfer learning DeepID. Sistem dirancang untuk memprediksi kepribadian secara otomatis melalui analisis video wajah. Studi ini berfokus pada penggunaan deteksi wajah MTCNN untuk mengekstraksi fitur penting yang diolah lebih lanjut dengan DeepID, serta klasifikasi kepribadian menggunakan *Support Vector Machine* (SVM). Model ini dikembangkan melalui beberapa tahap, termasuk pengumpulan dan persiapan data, ekstraksi fitur, serta evaluasi model. Evaluasi kinerja model dilakukan menggunakan *Confusion Matrix* dengan metrik seperti akurasi, presisi, recall, dan F1-score. Sistem diimplementasikan dalam sebuah aplikasi berbasis web menggunakan framework Flask, memanfaatkan Google Colab untuk pemrosesan data serta pengembangan model.

Kata kunci: *Big Five Personality, Transfer Learning, DeepID, Prediksi Kepribadian, Flask.*

ABSTRACT

PREDICTION PERSONALITY BASED VIDEO USING DEEPID TRANSFER LEARNING MODEL

Nama : Handika Dio Pradana
NIM : 21091397021
Program Studi : D4 Manajemen Informatika
Fakultas : Vokasi
Nama Lembaga : Universitas Negeri Surabaya
Pembimbing : Salamun Rohman Nudin, S.Kom., M..Kom.

This research develops a personality prediction system based on the Big Five Personality theory using the DeepID transfer learning method. The system is designed to predict personality automatically through facial video analysis. This study focuses on using MTCNN facial detection to extract important features which are further processed with DeepID, as well as personality classification using Support Vector Machine (SVM). This model was developed through several stages, including data collection and preparation, feature extraction, and model evaluation. Model performance evaluation is carried out using Confusion Matrix with metrics such as accuracy, precision, recall, and F1-score. The system is implemented in a web-based application using the Flask framework, utilizing Google Colab for data processing and model development.

Keywords: *Big Five Personality, Transfer Learning, DeepID, Personality Prediction, Flask*

KATA PENGANTAR

Alhamdulillah, dengan penuh rasa syukur Penulis haturkan puja dan puji syukur kehadirat Allah SWT. atas karunia dan rahmatnya sehingga penulis bisa menyusun proposal tugas akhir ini dengan lancar. Penulis persembahkan sebagai upaya mengimplementasikan ilmu yang penulis dapatkan dari Bapak/Ibu Dosen D4 Manajemen Informatika. Penyelesaian proposal ini tidak luput dari kerja keras berbagai pihak

Penulis ingin menyampaikan terima kasih kepada :

1. Bapak Prof. Dr. Nus Hasan, M.Kes. selaku Rektor Universitas Negeri Surabaya,
2. Bapak Suprpto, S.Pd., M.T. selaku Dekan Fakultas Vokasi Universitas Negeri Surabaya,
3. Bapak Dodik Arwin Dermawan, S.St., S.T., M.T. selaku Koordinator Program Studi D4 Manajemen Informatika,
4. Bapak Salamun Rohman Nudin, S.Kom., M.Kom., selaku Dosen Pembimbing,
5. Bapak/Ibu Dosen D4 Manajemen Informatika Fakultas Vokasi Universitas Negeri Surabaya,
6. Serta Keluarga yang selalu memberikan dukungan kepada Penulis..

Penulis menyadari bahwa proposal ini masih memerlukan perbaikan dan penyempurnaan lebih lanjut. Oleh karena itu penulis berharap dapat menerima kritik dan saran yang membangun dari pembaca. Semoga tugas akhir ini dapat bermanfaat untuk berkembangnya ilmu pengetahuan .

Surabaya, 18 November 2024

Penulis

DAFTAR ISI

HALAMAN PERSETUJUAN	III
ABSTRAK	IV
ABSTRCT	V
KATA PENGANTAR.....	VI
DAFTAR ISI	VII
DAFTAR GAMBAR.....	IX
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah.....	5
1.3 Tujuan Penelitian	5
1.4 Manfaat Penelitian.....	5
1.5 Batas Penelitian.....	6
BAB II KAJIAN PUSTAKA	7
2.1 Landasan Teori.....	7
2.1.1 Big Five Personality.....	7
2.1.2 Pengenalan Wajah (Face Recognition)	10
2.1.3 Computer Vision.....	10
2.1.4 Deep Learning	11
2.1.5 Convolutional Neural Network (CNN)	12
2.1.6 OpenCV (Open Computer Vision).....	15
2.1.7 MTCNN (Multi-task Cascaded Convolutional Neural Network)	16

2.1.8	DeepID	17
2.1.9	SVM	18
2.1.10	Optimizer.....	20
2.1.11	Confusion Matrix.....	22
2.1.12	Tensorflow	23
2.1.13	Keras	24
2.1.14	Flask	24
2.1.15	<i>Cross-Industry Standard Process for Data Mining (CRISP-DM)</i>	25
2.2	Hasil penelitian yang relevan.....	29
BAB III METODOLOGI PENELITIAN		31
3.1.	Tahap Analisis Masalah	31
3.1.1.	Identifikasi Masalah.....	32
3.1.2.	Studi Literatur.....	32
3.2.	Tahap Pengembangan Model dan Website	32
3.2.1	Pengumpulan Data	33
3.2.2	Persiapan Data.....	33
3.2.3	Pembangunan Model	34
3.2.4	Evaluasi.....	35
3.2.5	Desain Sistem	36
3.2.6	Penerapan Sistem	39
3.2.7	Pengujian Sistem	39
3.3.	Tahap Pelaporan.....	39
DAFTAR PUSTAKA		41

DAFTAR GAMBAR

<i>Gambar 2.1 Big Five Personality</i>	8
<i>Gambar 2.2 Tahapan Sistem Pengenalan Wajah</i>	10
<i>Gambar 2.3 Model Umum Computer Vision</i>	11
<i>Gambar 2.4 Deep Neural Network</i>	12
<i>Gambar 2.5 Proses Konvolusi CNN</i>	13
<i>Gambar 2.6 Operasi Konvolusi</i>	14
<i>Gambar 2.7 Operasi Max Polling</i>	15
<i>Gambar 2.8 Modular Struktur OpenCV</i>	16
<i>Gambar 2.9 Arsitektur MTCNN</i>	17
<i>Gambar 2.10 Arsitektur Model DeepID</i>	18
<i>Gambar 2.11 Penentuan Hyperplane</i>	19
<i>Gambar 2.12 Confusion matrix</i>	22
<i>Gambar 2.13 Arsitektur Umum Tensorflow</i>	23
<i>Gambar 2.14 Arsitektur Flask</i>	24
<i>Gambar 2.15 Metodologi CRISP-DM</i>	26
<i>Gambar 3.1 Diagram Alur Penelitian</i>	31
<i>Gambar 3.2 Diagram Alur Persiapan Data</i>	33
<i>Gambar 3.3 Diagram Alur Pengembangan Model</i>	34
<i>Gambar 3. 4 Diagram Alur Kerja Sistem</i>	37
<i>Gambar 3.6 Halaman Utama</i>	38
<i>Gambar 3.7 Halaman Preview Gambar</i>	38
<i>Gambar 3.8 Hasil Identifikasi Kepribadian</i>	39

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kepribadian bisa didefinisikan sebagai kombinasi dari perilaku, karakteristik, emosi, dan pola pikir seseorang (Suman dkk., 2022). Jadi, memahami kepribadian seseorang bisa menjadi aspek yang cukup penting dalam berbagai bidang, mulai dari psikologi, forensik, politik bahkan sampai ke interaksi manusia dan komputer. kepribadian ini menjadi faktor yang berpengaruh terhadap kehidupan seseorang, karena dapat menentukan bagaimana seseorang memilih pilihan hidup atau karir, kinerja, kesehatan, dan juga preferensi atau keinginan seseorang (Mehta dkk., 2020).

Deteksi kepribadian merupakan suatu bidang penelitian yang mempunyai tujuan untuk mengidentifikasi serta menganalisis suatu karakteristik psikologis yang melekat pada seorang individu (Alshouha dkk., 2024). Saat ini terdapat berbagai teori tentang ciri kepribadian yang sering digunakan, seperti DISC, MBTI dan Lima Besar (Big five personality).

DISC adalah alat asesmen kepribadian yang digunakan oleh lebih dari satu juta individu setiap tahun untuk meningkatkan kerjasama tim, komunikasi, dan produktivitas di lingkungan kerja. Ribuan organisasi di seluruh dunia, termasuk lembaga pemerintah besar, perusahaan Fortune 500, LSM, dan usaha kecil, memanfaatkan asesmen DISC. Tes kepribadian DISC dirancang untuk membantu organisasi menciptakan hubungan kerja yang lebih kuat dan efektif. DISC merupakan singkatan dari empat profil kepribadian utama

dalam model DISC: Dominance (D), Influence (i), Steadiness (S), dan Conscientiousness (C) (Beedu, 2021).

MBTI adalah pengukuran kepribadian yang menguraikan preferensi seseorang dalam empat dimensi, di mana masing-masing dimensi menggambarkan kecenderungan individu. Dimensi-dimensi tersebut meliputi: Introvert (I) - Extrovert (E): Mencerminkan orientasi sosial dan interaksi seseorang dengan lingkungannya; Intuition (N) - Sensing (S): Menggambarkan cara individu menerima dan memproses informasi; Thinking (T) - Feeling (F): Menunjukkan cara seseorang mengambil keputusan; Judgement (J) - Perception (P): Menandakan pendekatan individu terhadap kehidupan dan cara mereka berinteraksi dengan dunia luar. Keempat dimensi ini dapat digabungkan untuk menciptakan salah satu dari 16 tipe kepribadian yang merefleksikan karakteristik unik individu (Ryan dkk., 2023).

Big five personality merupakan model yang terdiri dari 5 dimensi utama yaitu *Openness* (keterbukaan terhadap hal baru), *Conscientiousness* (menggambarkan keteraturan dan tanggung jawab), *Extraversion* (kecenderungan bersosialisasi), *Agreeableness* (interaksi sosial dalam hubungan), dan *Neuroticism* (stabilitas emosional) atau yang sering dikenal dengan istilah *OCEAN* (Tinwala & Rauniyar, 2021). *Big Five Personality* telah menjadi salah satu kerangka atau model kepribadian yang paling banyak diadaptasi dalam literatur serta bisa diterima dan diakui banyak kalangan psikolog dan peneliti di seluruh dunia, dikarenakan konsisten dan akan tetap relevan dalam kehidupan seseorang.

Prediksi atau pengukuran kepribadian sering kali dilakukan melalui kuesioner, hal ini memiliki beberapa keterbatasan yang dapat mempengaruhi hasil dari prediksi atau pengukuran kepribadian tersebut, misal faktor seperti kejujuran dan kondisi psikologis responden. Dengan hanya mengisi kuesioner, responden bisa saja memanipulasi atau tidak memberikan jawaban yang akurat sesuai dengan kondisi yang sebenarnya dari responden tersebut.

Dengan kemajuan teknologi seperti saat ini, khususnya dengan berkembangnya *deep learning*, dapat memunculkan peluang untuk mengembangkan sebuah metode baru yang bisa membantu dalam memprediksi atau mengukur kepribadian seseorang dengan lebih akurat. Dalam beberapa penelitian dapat dikaitkan hubungan antara bentuk wajah seseorang dengan kepribadian yang dimiliki orang tersebut, misalnya penelitian sebelum yang dilakukan oleh (Suman dkk., 2022) telah menggunakan potongan video pendek untuk menganalisis kepribadian dari orang-orang yang ada di potongan video tersebut. Arsitektur model berbasis CNN yang telah dilatih sebelumnya digunakan untuk mengekstraksi fitur dari gambar yang sebagian besar fitur wajah. Dengan beberapa penelitian yang ada, prediksi kepribadian di klasifikasikan menjadi dua jenis berdasarkan inputnya, yakni *single-modal* dan *multi-modal*. *Single-modal* hanya menggunakan audio-video atau teks, sedangkan *multi-modal* menggabungkan data dari modalitas lain termasuk teks, audio, dan informasi visual (Nagaraja & Revathi, 2023).

Terdapat beberapa alasan teoritis yang bisa menghubungkan antara wajah seseorang dengan kepribadian yang dimilikinya. Pertama, karena korelasi genetik karakteristik kraniofasial, jadi selain membentuk

wajah, gen berperan dalam pembentukan sifat kepribadian seseorang. Kedua, beberapa bukti menunjukkan bahwa hormon seperti testosteron, estrogen, prenatal, dan postnatal, memang mempengaruhi perilaku dan fitur wajah. Ketiga, persepsi fitur wajah, sama halnya dengan persepsi 'kepandaian' seseorang yang dapat digunakan untuk prediksi pencapaian pendidikan, prasangka atau persepsi fitur wajah seseorang bisa mengarah pada pengembangan karakteristik seseorang yang maladaptif (misal '*Quasimodo Complex*'). Keempat, kepribadian seseorang bisa dikaitkan dengan perilaku ekspresif secara emosional, yang mengarah pada perkembangan otot wajah dan kerutan (Kachur dkk., 2020). Oleh karena itu, penggunaan video pengenalan diri bisa dijadikan sebagai sumber data untuk analisis dan prediksi kepribadian seseorang dengan relevan, terutama dalam konteks *Big Five Personality* ini.

Penelitian ini akan menggunakan teknik ekstraksi yang berbasis OpenCV, MTCNN, dan DeepFace yang digunakan untuk menentukan dan menganalisis fitur wajah dari video pengenalan diri, dimana MTCNN akan mendeteksi dan menentukan landmark wajah seseorang, dan DeepID akan membantu menganalisis ekspresi pada wajah seseorang berdasarkan landmark yang telah ditentukan sebelumnya oleh MTCNN. Untuk model klasifikasi dalam memprediksi dimensi Big Five Personality berdasarkan fitur wajah yang telah diekstraksi, akan menggunakan Support Vector Machine (SVM). Algoritma Adam akan digunakan untuk mengoptimisasi atau meningkatkan akurasi dari model tersebut.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, maka rumusan masalah untuk penelitian ini sebagai berikut :

1. Bagaimana implementasi OpenCV, dan MTCNN untuk mendeteksi wajah?
2. Bagaimana proses ekstraksi fitur wajah seseorang menggunakan transfer learning model DeepID?
3. Bagaimana SVM digunakan untuk mengklasifikasikan kepribadian seseorang berdasarkan fitur wajah yang telah di ekstraksi?

1.3 Tujuan Penelitian

Adapun tujuan dari penelitian ini sebagai berikut :

1. Mengembangkan model sistem prediksi *Big Five Personality* berbasis video menggunakan deep learning.
2. Implementasi SVM dalam mengklasifikasi dimensi *Big Five Personality*.
3. Implementasi algoritma Adams untuk optimisasi dan peningkatan akurasi model.

1.4 Manfaat Penelitian

Adapun manfaat dari penelitian ini sebagai berikut :

1. Pengembangan metode prediksi *Big Five Personality* dengan lebih akurat.
2. Membuka peluang untuk pengaplikasian praktis di berbagai bidang misalkan rekrutmen tenaga kerja atau analisis psikologi.

1.5 Batas Penelitian

Batasan masalah pada penelitian ini meliputi :

1. Analisis kepribadian penelitian ini hanya berfokus pada *Big Five Personality* (OCEAN).
2. Pengklasifikasian hanya dilakukan dengan menggunakan *Support Vector Machine* (SVM), tanpa mempertimbangkan metode klasifikasi lainnya.
3. Model transfer learning yang digunakan untuk ekstraksi fitur wajah hanya terbatas pada ekstraksi model *DeepID*.
4. Evaluasi akan difokuskan pada hasil *convolution-matrix* yang diperoleh dari model transfer learning *DeepID*.
5. Lingkungan Pengembangan hanya menggunakan *Google Colaboratory* dan terbatas pada bahasa pemrograman python.

BAB II

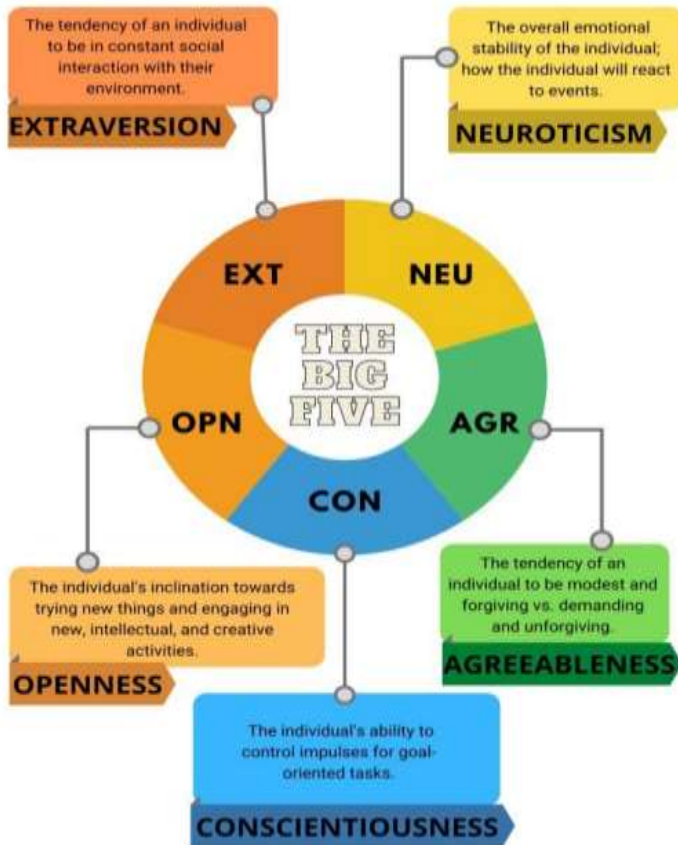
KAJIAN PUSTAKA

2.1 Landasan Teori

Landasan teori adalah dasar atau fondasi konseptual yang digunakan untuk mendukung sebuah penelitian. Mencakup kerangka konseptual, prinsip, teori, hipotesis, model, dan teknologi yang kemudian disusun berfokus pada permasalahan dalam penelitian. Landasan teori ini digunakan untuk menjelaskan atau menjawab pertanyaan penelitian serta mengarahkan dan memperkuat pemahaman terhadap subjek yang sedang diteliti dengan memberikan konteks yang diperlukan untuk menafsirkan data dan hasil penelitian.

2.1.1 Big Five Personality

Big Five Personality adalah sebuah teori klasifikasi kepribadian yang dikemukakan oleh Lewis Goldberg yang bisa digunakan secara konsisten dan seragam sepanjang hidup seseorang untuk mengevaluasi kepribadian seseorang dengan mengacu pada lima faktor atau dimensi kunci (Tinwala & Rauniyar, 2021).



Gambar 2.1 Big Five Personality
(Tinwala & Rauniyar, 2021)

lima dimensi kunci dalam Big Five Personality Model atau yang biasa dikenal sebagai "OCEAN" ini yaitu:

1. Openness (OPN) : sifat ini menunjukkan kecenderungan seseorang untuk mencoba dan terlibat dalam kegiatan baru. Nilai tinggi pada karakteristik ini menunjukkan seseorang memiliki imajinatif dan tidak konvensional, dan nilai rendah

menunjukkan seseorang lebih menyukai cara-cara rutin atau biasa dan konvensional.


2. Conscientiousness (CON) : sifat ini menunjukkan kecenderungan seseorang untuk mampu menyelesaikan tugas-tugas yang berorientasi pada tujuan. Nilai tinggi pada karakteristik ini menunjukkan bahwa seseorang mampu untuk terorganisir, bertanggung jawab, tekun, dan patuh pada aturan, sedangkan nilai rendah menunjukkan bahwa orang tersebut cenderung ceroboh, suka menunda-nunda, dan tidak terorganisir.
3. Extraversion (EXT) : sifat ini menunjukkan kecenderungan seseorang untuk terlibat dalam interaksi sosial baik sosial maupun lingkungannya. Nilai tinggi pada karakteristik ini menunjukkan seseorang cenderung suka bergaul dan menjadi pusat perhatian, sedangkan nilai rendah menunjukkan seseorang bersifat pendiam, suka menyendiri daripada bersosialisasi, dan tidak ingin menjadi pusat perhatian.
4. Agreeableness (AGR) : sifat ini menunjukkan bagaimana seseorang memperlakukan orang lain dalam sebuah hubungan. Nilai tinggi pada karakteristik ini menunjukkan seseorang sebagai orang yang jujur, rendah hati, pengertian, dan pemaaf, sedangkan nilai rendah menunjukkan seseorang sebagai orang yang kasar, penuntut, keras kepala, dan tidak peduli.
5. Neuroticism (NEU) : sifat ini menunjukkan stabilitas emosional seseorang secara keseluruhan. Nilai tinggi pada karakteristik ini menunjukkan seseorang cenderung mudah tersinggung, mudah cemas, dan perubahan suasana hati yang cepat, sedangkan nilai rendah menunjukkan seseorang lebih tenang, percaya diri, dan tangguh.

2.1.2 Pengenalan Wajah (Face Recognition)

Pengenalan wajah (Face Recognition) merupakan suatu pengembangan dari teknologi deteksi wajah (Face Detection) yang mana teknologi ini dapat menghasilkan wajah dari hasil tangkapan kamera dan akan melakukan deteksi persamaan wajah dengan data wajah yang telah disimpan di database pada komputer, sehingga komputer dapat mengenali dan mengetahui identitas wajah seseorang tersebut (L. W. Alexander dan S. Sentinuwo., 2017)

Cara kerja pengenalan wajah secara umum yaitu dengan mengkonversikan foto, sketsa, dan gambar video menjadi serangkaian angka, yang disebut dengan faceprint yang kemudian akan membandingkan dengan rangkaian angka yang lain yang mewakili wajah-wajah yang sudah dikenal. Proses pengenalan citra wajah oleh sistem secara garis besar dapat dibagi menjadi lima tahap seperti deteksi, pengenalan posisi, normalisasi, pengkodean, perbandingan (R. Wiryadinata dkk., 2016)

Sistem pengenalan wajah dibagi menjadi 3 tahapan yaitu deteksi wajah, ekstraksi fitur dan pengenalan wajah, dapat dilihat pada gambar 2.2.

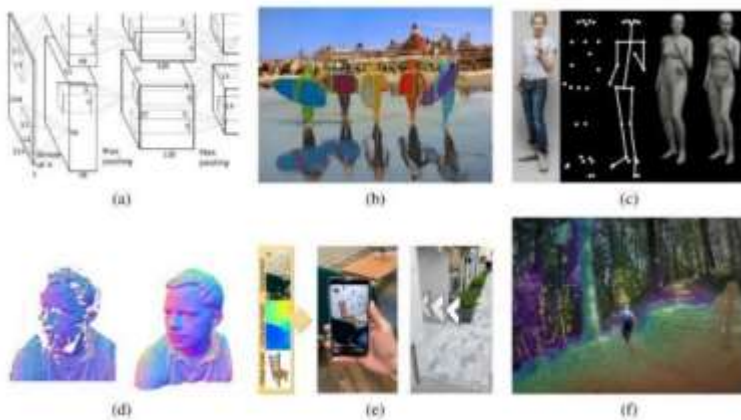


Gambar 2.2 Tahapan Sistem Pengenalan Wajah
(M. Chihaoui dkk, 2016)

2.1.3 Computer Vision

Computer Vision (CV) adalah bidang studi yang bertujuan untuk mengembangkan kemampuan komputer dalam memperoleh pemahaman tingkat tinggi dari gambar atau video


digital, yang berperan dalam membantu pengambilan keputusan di lingkungan nyata (Heidari dkk., 2024). Saat ini, sistem *computer vision* mendukung berbagai sistem, seperti manufaktur, ritel, dan keuangan, dalam memperluas bisnis dan memperkuat kemampuan AI di edge. Fungsi utama dalam sistem *computer vision* modern mencakup deteksi objek, pengenalan objek, serta klasifikasi objek (Intel, 2024).



Gambar 2.3 Model Umum Computer Vision
(Szeliski, 2022)

2.1.4 Deep Learning

Deep Learning adalah salah satu cabang machine learning yang lebih baik dari model Machine Learning yang lebih dangkal untuk menangani data yang besar dan kompleks, dan kemampuan belajar dari data tanpa pemrograman khusus. Metode ini memungkinkan diterapkan dalam banyak pengaplikasian yang melibatkan teks, gambar, suara, dan video. Cara kerja Deep Learning ini berfokus pada penggunaan jaringan saraf buatan dengan banyak lapisan (Deep Neural Network) untuk menganalisis data (Janiesch dkk., 2021).



Gambar 2.4 Deep Neural Network
(Janiesch dkk., 2021).


Deep learning mampu mengekstarksi fitur dan pola dari sebuah data kompleks secara otomatis, yang membuatnya unggul dalam tugas pengenalan wajah, deteksi objek, pemrosesan bahasa alami, dan banyak lagi. Setiap layer atau lapisan jaringan saraf bekerja untuk mempelajari fitur data yang kompleks dari pola dasar atau lapisan awal, hingga ke representasi yang lebih kompleks.

2.1.5 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan pengembangan dari Multilayer Perceptron (MLP) yang didesain untuk mengolah data dua dimensi (Li dkk., 2022). CNN termasuk dalam kategori Deep Neural Network karena kedalaman jaringan yang tinggi dan banyak diaplikasikan pada data gambar. Pada klasifikasi gambar, MLP kurang sesuai untuk digunakan karena tidak menyimpan informasi spasial dari data gambar dan menganggap setiap piksel adalah fitur yang independen sehingga menghasilkan hasil yang kurang baik.

CNN memiliki cara kerja yang mirip dengan MLP, namun dalam CNN setiap neuron dipresentasikan dalam bentuk dua dimensi, tidak seperti MLP yang setiap neuron hanya berukuran satu dimensi. Karena sifat proses konvolusi, maka CNN hanya

bisa digunakan pada data yang memiliki struktur dua dimensi seperti gambar dan suara.




Gambar 2.5 Proses Konvolusi CNN
(Kiranyaz dkk., 2021)

Sebuah CNN tersusun dari beberapa lapisan atau layer antara lain convolution, subsampling atau pooling layer, dan fully connected layer.

1. Convolution Layer


Konvolusi merupakan suatu istilah matematis yang berarti mengaplikasikan sebuah fungsi pada output fungsi lain secara berulang (O'Shea & Nash., 2015). Dalam pengolahan gambar, konvolusi memiliki arti mengaplikasikan sebuah kernel (kotak kuning) pada gambar di semua offset yang memungkinkan seperti yang ditunjukkan pada Gambar 2.6 Kotak hijau secara keseluruhan adalah gambar yang akan dikonvolusi. Kernel bergerak dari sudut kiri atas ke kanan bawah. Sehingga hasil konvolusi dari gambar tersebut dapat dilihat pada gambar disebelah kanannya. Tujuan dilakukannya konvolusi pada data, untuk mengekstraksi fitur dari input. Konvolusi menghasilkan transformasi linear dari data input sesuai informasi spasial pada data. Bobot pada layer tersebut menspesifikasikan kernel konvolusi yang digunakan, sehingga kernel konvolusi dapat dilatih berdasarkan input pada CNN.



Gambar 2.6 Operasi Konvolusi
(O'Shea & Nash., 2015)

2. Subsampling Layer

Subsampling adalah proses mereduksi ukuran sebuah data citra. Dalam pengolahan citra, subsampling juga bertujuan untuk meningkatkan invariansi posisi dari fitur. Dalam sebagian besar CNN, metode subsampling yang digunakan adalah max pooling. Max pooling membagi output dari convolution layer menjadi beberapa grid kecil lalu mengambil nilai maksimal dari setiap grid untuk menyusun matriks citra yang telah direduksi seperti yang ditunjukkan pada Gambar 2.7. Grid yang berwarna merah, hijau, kuning dan biru merupakan kelompok grid yang akan dipilih nilai maksimumnya. Sehingga hasil dari proses tersebut dapat dilihat pada kumpulan grid disebelah kanannya. Proses tersebut memastikan fitur yang didapatkan akan sama meskipun objek citra mengalami translasi (pergeseran).



Gambar 2.7 Operasi Max Polling
(K. Parthy., 2018)


3. Fully Connected Layer

Layer tersebut adalah layer yang biasanya digunakan dalam penerapan MLP dan bertujuan untuk melakukan transformasi pada dimensi data agar data dapat diklasifikasikan secara linear. Setiap neuron pada convolution layer perlu ditransformasi menjadi data satu dimensi terlebih dahulu sebelum dapat dimasukkan ke dalam sebuah fully connected layer. Karena hal tersebut menyebabkan data kehilangan informasi spasialnya dan tidak reversibel, fully connected layer hanya dapat diimplementasikan di akhir jaringan. Convolution layer dengan ukuran kernel 1×1 melakukan fungsi yang sama dengan sebuah fully connected layer namun dengan tetap mempertahankan karakter spasial dari data. Hal tersebut membuat penggunaan fully connected layer pada CNN sekarang tidak banyak dipakai (I. Putra., 2016).

2.1.6 OpenCV (Open Computer Vision)

OpenCV atau Open Conmputer Vision adalah library perangkat lunak open-source yang mencakup computer vision, machine learning, dan pemrosesan gambar secara realtime. OpenCV dapat mendeteksi tulisan tangan, wajah, dan objek dalam gambar. Kombinasi dengan pustaka lain seperti NumPy memungkinkan analisis struktur larik; pustaka ini berbeda dari

Matlab yang lebih umum dan ditujukan untuk pemrosesan gambar. Algoritma OpenCV melacak video berurutan, dan pemilihan algoritma harus disesuaikan dengan tujuan penggunaan (Shubham Mishra dkk., 2022).




Gambar 2.8 Modular Struktur OpenCV
(Ralev & Krastev, 2022)

Karena sifatnya yang open-source atau terbuka, serta menyediakan banyak modul yang bisa digunakan untuk analisis data visual, OpenCV menjadi salah satu library computer vision terpopuler di kalangan praktisi dan peneliti, dengan lebih dari 2500 fungsi yang siap dipakai dalam berbagai kebutuhan pemrosesan visual.

2.1.7 MTCNN (Multi-task Cascaded Convolutional Neural Network)

Library yang digunakan dalam pendeteksian wajah adalah MTCNN. Algoritma MTCNN bekerja dalam tiga langkah dan menggunakan satu jaringan saraf untuk masing-masingnya. Bagian pertama adalah jaringan proposal. Ini akan memprediksi posisi wajah potensial dan kotak pembatas mereka seperti jaringan perhatian di Faster R-CNN. Hasil dari langkah ini adalah sejumlah besar deteksi wajah dan banyak deteksi palsu.

Bagian kedua menggunakan gambar dan output dari prediksi pertama. Itu membuat penyempurnaan dari hasil untuk menghilangkan sebagian besar deteksi palsu dan kotak pembatas agregat. Bagian terakhir bahkan lebih menyempurnakan prediksi dan menambahkan prediksi landmark wajah.




Gambar 2.9 Arsitektur MTCNN
(Ku & Dong, Wei, 2020)

2.1.8 DeepID

DeepID adalah sebuah model pembelajaran mendalam (deep learning) yang dirancang khusus untuk tugas identifikasi wajah. Model ini telah menjadi salah satu pendekatan yang paling populer dan efektif dalam bidang pengenalan wajah, dengan akurasi yang tinggi dan kemampuan generalisasi yang baik. DeepID didasarkan pada arsitektur jaringan saraf konvolusional (Convolutional Neural Network, CNN) yang dalam. CNN sangat cocok untuk memproses data gambar karena kemampuannya dalam mengekstrak fitur-fitur hierarkis dari gambar. DeepID menggunakan beberapa lapisan konvolusional untuk mengekstrak fitur-fitur wajah yang semakin abstrak, mulai dari tepi, tekstur, hingga struktur wajah secara keseluruhan.


Secara garis besar, ekstraksi fitur dapat dijelaskan pada Gambar 2.10 DeepID menerima gambar wajah sebagai input dan kemudian mengekstrak fitur-fitur wajah yang relevan menggunakan lapisan-lapisan konvolusional. Fitur-fitur ini merepresentasikan informasi yang paling penting tentang identitas seseorang, seperti bentuk mata, hidung, dan mulut. Fitur-fitur yang telah diekstrak kemudian dipetakan ke dalam sebuah ruang fitur berdimensi tinggi. Ruang fitur ini merupakan representasi numerik dari wajah seseorang. Terakhir, sebuah klasifikator (misalnya, softmax) digunakan untuk menentukan identitas seseorang berdasarkan representasi fitur yang telah dihasilkan.



Gambar 2.10 Arsitektur Model DeepID
(Yi Sun., 2014)

2.1.9 SVM

SVM (Support Vector Machine) dalam machine learning dikenal juga dengan support vector network yang merupakan metode supervised terkait dengan learning algorithm untuk analisa pola data yang digunakan untuk klasifikasi dan regresi. SVM merupakan usaha mencari hyperplane terbaik yang berfungsi sebagai pemisah dua buah class pada input space (Sheth dkk., 2022).



Gambar 2.11 Penentuan Hyperplane
(Dania Siregar dkk., 2023)

Gambar 2.11 memperlihatkan beberapa pattern yang merupakan anggota dari dua buah class : +1 dan -1. Pattern yang tergabung pada class -1 disimbolkan dengan warna merah (kotak), sedangkan pattern pada class +1, disimbolkan dengan warna kuning (lingkaran). Permasalahan klasifikasi dapat diterjemahkan dengan usaha menemukan garis (hyperplane) yang memisahkan antara kedua kelompok tersebut.

Hyperplane pemisah terbaik antara kedua class dapat ditemukan dengan mengukur margin hyperplane dan mencari titik optimum hyperplane tersebut. Margin adalah jarak antara hyperplane dengan pattern terdekat dari masingmasing kelas. Pattern yang paling dekat disebut sebagai support vector. Garis solid pada menunjukkan hyperplane yang terbaik, yaitu yang terletak tepat pada tengah-tengah kedua class, sedangkan titik merah dan kuning yang berada dalam lingkaran hitam adalah support vector. Usaha untuk mencari lokasi hyperplane ini merupakan inti dari proses pembelajaran pada SVM.

2.1.10 Optimizer

Optimisasi merupakan salah satu komponen penting dalam pelatihan model machine learning dan deep learning, pemilihan algoritma untuk optimisasi atau optimizer yang tepat bisa mempengaruhi efektivitas dan efisiensi proses pelatihan model, dan setiap optimizer memiliki fitur khusus yang dapat disesuaikan dengan kebutuhan atau karakteristik data yang akan diolah. Terdapat beberapa algoritma optimisasi yang tersedia :

1. Adam

Adam atau Adaptive Moment Estimation merupakan salah satu algoritma optimisasi adaptif yang sering digunakan dalam pelatihan model machine learning dan deep learning sebagai pengganti stochastic gradient reduction tradisional karena dinilai sangat efisien. Algoritma ini menggunakan metode yang menggabungkan RMSProp dan momentum dengan menggunakan rata-rata eksponensial dari gradien (m_t) dan gradien kuadrat (v_t) sehingga meningkatkan performa pelatihan model machine learning (Reyad dkk., 2023). Berikut adalah persamaan untuk menghitung algoritma Adam :

$$\begin{aligned}
 m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t \\
 v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \\
 \hat{m}_t &= \left(\frac{m_t}{1 - \beta_1^t} \right) \quad \hat{v}_t = \left(\frac{v_t}{1 - \beta_2^t} \right) \\
 \theta_{t+1} &= \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t
 \end{aligned} \tag{2.1}$$

Dimana β_1 adalah laju penyusutan eksponensial. Nilai default β_1 dan β_2 adalah 0,9 dan 0,999. \hat{m}_t dan \hat{v}_t adalah bias koreksi untuk m_t dan v_t .

2. RMSProp

RMSProp atau Root Mean Square Propagation merupakan salah satu algoritma optimisasi yang dimaksudkan untuk mengatasi masalah laju pembelajaran yang sering terjadi pada SGD, dengan menyesuaikan laju pembelajaran setiap parameter menggunakan rata-rata bergerak dari kuadrat gradien, sehingga memungkinkan algoritma ini untuk mengambil langkah kecil ketika gradien besar, dan langkah besar ketika gradien kecil, jadi konvergensi bisa dipercepat (Reyad dkk., 2023). Berikut adalah persamaan untuk menghitung RMSProp :

$$\begin{aligned} g_t &= \nabla_{\theta_t} J(\theta_t) \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \\ \theta_{t+1} &= \theta_t - \frac{\eta}{\sqrt{v_t + \epsilon}} g_t \end{aligned} \quad (2.2)$$

Dimana g_t adalah turunan pertama dari fungsi kerugian (gradien) dan β_2 adalah laju penyusutan eksponensial

3. SGD


SGD atau Stochastic Gradient Descent merupakan salah satu metode optimisasi yang paling dasar, biasanya digunakan untuk mempercepat proses pelatihan model machine learning, dimana cara kerjanya adalah dengan memperbarui parameter model berdasarkan subset acak dari data mini-batch, dibandingkan seluruh dataset, sehingga lebih cepat (Reyad dkk., 2023). Berikut adalah persamaan untuk menghitung RMSProp :

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla_{\theta} J(\theta_t; x^{(i)}; y^{(i)}) \quad (2.3)$$

Dimana η adalah laju pembelajaran, $\nabla_{\theta} J(\theta_t)$ adalah gradien fungsi kerugian terhadap $J(\theta_t)$, selain itu $x^{(i)}$ dan $y^{(i)}$ merepresentasikan data pelatihan dalam pasangan input-output. Jika kurva loss function memiliki titik pelana dimana satu dimensi miring ke atas, dan dimensi lainnya miring ke bawah, algoritma ini tidak akan bekerja dengan baik.

2.1.11 Confusion Matrix

Sebuah sistem yang melakukan klasifikasi tentunya diharapkan bisa memprediksi dengan benar. Namun tidak dapat dipungkiri jika pada penerapannya sistem tidak akan bisa 100% benar. Hal ini yang mengharuskan pengukuran kinerja dari sistem tersebut untuk mengetahui berbagai aspek pengujiannya. Pengukuran kinerja klasifikasi dilakukan dengan confusion matrix.



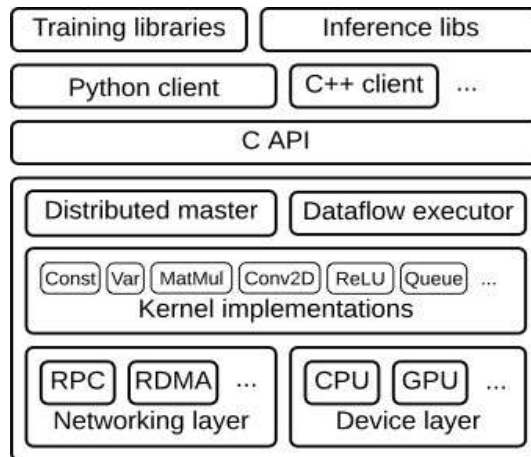
Gambar 2.12 Confusion matrix
(Krüger., 2016)

Multiclass confusion matrix juga memiliki elemen TP (True Positive), FN (False Negative), FP (False Positive), dan TN (True Negative). Berikut adalah ketentuan dalam menetapkan nilai elemen tersebut:

- a. TP (True Positive) merupakan banyaknya data yang kelas aktualnya sama dengan kelas prediksinya.
- b. FN (False Negative) merupakan total dari seluruh baris yang ditunjuk kecuali TP yang dicari.
- c. FP (False Positive) merupakan total dari seluruh kolom yang ditunjuk kecuali TP yang dicari.
- d. TN (True Negative) merupakan total dari seluruh kolom dan baris selain yang ditunjuk.

2.1.12 Tensorflow

TensorFlow adalah open source library untuk machine learning yang di release oleh Google yang mendukung beberapa bahasa pemrograman. Dalam proses Transfer Learning, Tensorflow berperan untuk memproses Model untuk di training ulang menggunakan data yang baru dan kemudian menghasilkan classifier dengan komputasi yang cepat dan akurasi yang baik. Tensorflow dapat digunakan pada semua sistem operasi. Arsitektur umum dari Tensorflow dapat dilihat pada Gambar 2.13.




Gambar 2.13 Arsitektur Umum Tensorflow
(Tensorflow., 2024)

2.1.13 Keras

Keras adalah API deep learning tingkat tinggi yang berjalan di atas TensorFlow, Theano, dan CNTK, dan berbasis alur graph. API ini bertujuan untuk menyederhanakan implementasi algoritma deep learning dengan mengurangi upaya membangun jaringan yang kompleks dari pendekatan konvensional yang membutuhkan waktu berjam-jam atau berhari-hari dalam pengimplementasian kode umum serta menjelaskan kesalahan pengguna untuk ditidaklanjuti (Joshi dkk., 2020).

2.1.14 Flask

Flask merupakan sebuah microframework web yang dikembangkan oleh Armin Ronacher menggunakan bahasa pemrograman python, dan memungkinkan penggunaanya untuk membangun sebuah aplikasi web dengan cepat tanpa mengkhawatirkan low-level tasks seperti protokol dan thread management karena desainnya yang ringan dan fleksibel. Framework ini menggunakan Werkzeug WSGI toolkit untuk server dan Jinja2 template engine yang membantu dalam pembuatan dan penyajian konten HTML yang dinamis (Maulid, 2021).




Gambar 2.14 Arsitektur Flask
(Ding dkk., 2012)

Flask menyediakan berbagai fitur dasar yang bisa mempermudah pengembangan aplikasi web, seperti routing URL, manajemen sesi, dan dukungan HTTP request, yang tidak membebani pengembang dengan banyak komponen yang tidak diperlukan.

2.1.15 *Cross-Industry Standard Process for Data Mining (CRISP-DM)*

CRISP-DM, atau *Cross-Industry Standard Process for Data Mining*, adalah metodologi yang teruji dalam industri untuk mengarahkan proyek *data mining*. Model ini merinci fase utama proyek, tugas-tugas di setiap fase, serta hubungan antar-tugas, yang memberikan panduan menyeluruh tentang siklus hidup *data mining* (IBM, 2021). Dirilis pada 1999 untuk menyatukan proses *data mining* di berbagai industri, CRISP-DM telah menjadi metodologi utama untuk proyek *data mining*, analitik, dan data sains. Penerapan CRISP-DM yang fleksibel bersama manajemen proyek *agile* berbasis tim cenderung menghasilkan performa terbaik (Hotz, 2024).

CRISP-DM terdiri dari enam tahap berulang, mulai dari pemahaman bisnis hingga implementasi. Gambar 2.14 menunjukkan tahapan dalam proses data mining.



*Gambar 2.15 Metodologi CRISP-DM
(Brzowska dkk., 2023)*

Tahapan dalam CRISP-DM bersifat fleksibel, memungkinkan peralihan antar-tahap sesuai kebutuhan. Hasil dari tiap fase menentukan langkah atau tugas selanjutnya yang harus dilaksanakan. Panah menunjukkan keterkaitan utama serta frekuensi transisi antar-fase. Lingkaran luar pada Gambar 1 menggambarkan siklus berkelanjutan dalam data mining. Proses data mining tidak berakhir setelah solusi diterapkan; wawasan yang diperoleh sepanjang proses dan dari solusi yang diterapkan dapat memunculkan pertanyaan bisnis baru yang lebih merinci. Pengalaman ini akan meningkatkan efektivitas proses data mining di masa mendatang (Brzowska dkk., 2023).

Berikut ini, merupakan uraian fase-fase proses *data mining* secara singkat:

1) *Business Understanding*

Fase awal ini berfokus pada pemahaman tujuan dan kebutuhan proyek dari perspektif bisnis, kemudian mengonversinya menjadi definisi masalah data mining serta rencana awal yang dirancang untuk mencapai tujuan tersebut.

2) *Data Understanding*

Fase *data understanding* dimulai dengan pengumpulan data awal dan dilanjutkan dengan kegiatan untuk mengenali data, mengidentifikasi masalah kualitas data, menemukan wawasan awal dari data, atau mendeteksi subset menarik untuk membentuk hipotesis mengenai informasi yang tersembunyi.

3) *Data Preparation*

Fase *data preparation* mencakup semua kegiatan yang diperlukan untuk membangun dataset akhir dari data mentah awal. Tugas persiapan data dapat dilakukan secara berulang dan tidak terikat pada urutan tertentu. Kegiatan ini meliputi pemilihan tabel, rekaman, dan atribut, serta transformasi dan pembersihan data untuk alat pemodelan. Pemilihan data harus dilakukan dengan menetapkan kriteria inklusi dan eksklusi. Kualitas data yang buruk dapat diperbaiki melalui proses pembersihan. Bergantung pada model yang digunakan yang ditentukan pada fase pertama, atribut turunan juga perlu disusun. Berbagai metode dapat diterapkan pada setiap langkah, tergantung pada model yang digunakan.

4) *Modeling*

Pada fase ini, berbagai teknik pemodelan dipilih dan diterapkan, serta parameternya disesuaikan untuk

mencapai nilai optimal. Umumnya, terdapat beberapa teknik untuk jenis masalah data mining yang sama, dan beberapa teknik memiliki persyaratan khusus terkait format data. Oleh karena itu, sering kali diperlukan untuk kembali ke fase persiapan data. Pemilihan teknik tergantung pada masalah bisnis dan karakteristik data, dengan penjelasan yang jelas mengenai alasan pemilihan tersebut. Dalam proses pembangunan model, parameter tertentu perlu ditetapkan, dan untuk menilai model, perlu dilakukan evaluasi berdasarkan kriteria tertentu untuk memilih model yang terbaik.

5) *Evaluation*

Pada tahap ini, model atau beberapa model telah dikembangkan dan menunjukkan kualitas tinggi dalam analisis data. Sebelum melanjutkan ke penerapan akhir model, penting untuk melakukan evaluasi menyeluruh terhadap model serta meninjau langkah-langkah yang dilakukan dalam konstruksinya untuk memastikan bahwa model tersebut memenuhi tujuan bisnis secara efektif. Salah satu tujuan utama adalah mengidentifikasi apakah ada isu bisnis penting yang belum cukup diperhatikan. Di akhir fase ini, keputusan mengenai pemanfaatan hasil data mining harus diambil.

6) *Deployment*

Pembuatan model biasanya bukan akhir dari proyek. Pengetahuan yang diperoleh harus diorganisir dan disajikan agar dapat dimanfaatkan oleh pelanggan, seringkali melalui penerapan model "langsung" dalam pengambilan keputusan, seperti personalisasi halaman web atau penilaian basis data pemasaran. Fase *deployment* dapat berupa laporan sederhana atau implementasi proses data mining yang kompleks di seluruh perusahaan. Umumnya, langkah penerapan dilakukan

oleh pelanggan, sehingga penting bagi mereka untuk memahami tindakan yang diperlukan untuk memanfaatkan model yang telah dibuat.

2.2 Hasil penelitian yang relevan

Hasil penelitian yang relevan berisi tentang studi yang telah dilakukan oleh peneliti sebelumnya dan telah dipublikasikan dalam literatur ilmiah. Hal ini bertujuan untuk memperkuat landasan teoritis, mendukung proses analisis data, serta meningkatkan pemahaman terhadap bidang yang sedang diteliti.

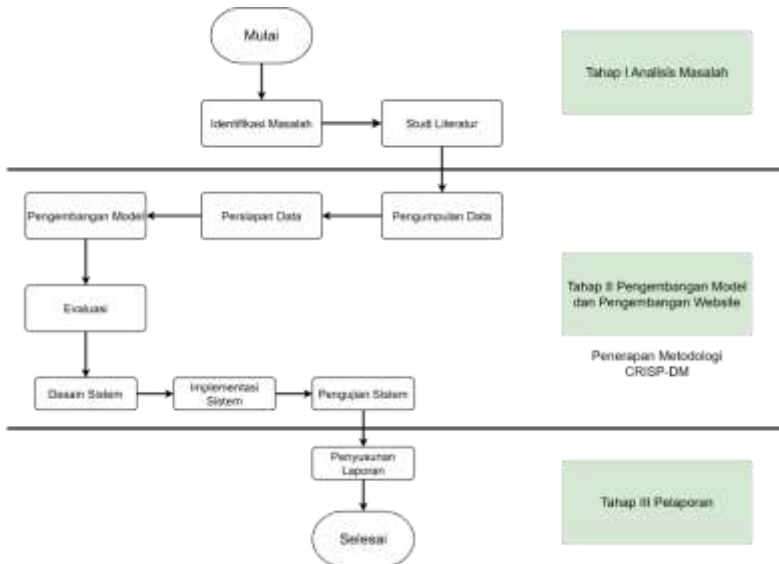
Penelitian	Data	Hasil akurasi
A Multi-Modal Personality Prediction System (Suman dkk., 2022)	Dataset yang digunakan pada penelitian ini berasal dari kompetisi ChaLearn LAP yang berisi 1.000 video yang dianotasi berdasarkan Big-Five Personality.	akurasi tertinggi menggunakan pendekatan berbasis CNN mencapai 91,43%.
Knock Knock, Whos's There: Facial Recognition using CNN-Based Classifiers (Sun & Redei, 2022)	Dataset yang digunakan pada penelitian ini menggunakan dataset Youtube Faceset (YTF) yang terdiri 621.126 gambar dari 1.595 identitas.	Hasil akurasinya mencapai 84,6%.
Deep Learning Face Representation from Predicting 10,000 Classes (Yi	Penelitian ini menggunakan dataset CelebFaces+ yang terdiri dari 202, 599	Akurasi verifikasi sebesar 97,45%

Sun., 2014)	gambar wajah dari 10, 177 selebriti, dan di prediksi menggunakan model transfer learning DeepID	
Deep Learning Face Representation by Joint Identification-Verification (Yi Sun., 2014)	Penelitian ini menggunakan dataset LFW dataset yang berisi 13.233 citra wajah dari 5.749 identitas dikumpulkan dari Internet. diprediksi menggunakan model transfer learning DeepID	Akurasi verifikasi wajah tercapai 99,15%

BAB III

METODOLOGI PENELITIAN

Penelitian ini direncanakan melalui beberapa tahap yang didapatkan melalui penyesuaian metodologi *Cross-Industry Standard Process for Data Mining* (CRISP-DM) sebagai rujukan metode analisis serta metode pengembangan aplikasi. Tahapan yang dihasilkan adalah sebagai berikut:



Gambar 3.1 Diagram Alur Penelitian

3.1. Tahap Analisis Masalah

Penelitian ini dimulai dengan tahap analisis masalah sebagai langkah awal dari keseluruhan proses penelitian. Analisis ini meliputi pemilihan topik, perumusan masalah, serta penentuan tujuan penelitian, yang akan didukung oleh tinjauan literatur terkait topik prediksi kepribadian berbasis video menggunakan model transfer learning DeepID. Tahap analisis masalah ini

menjadi landasan penting yang akan mengarahkan langkah-langkah selanjutnya dalam penelitian ini.

3.1.1. Identifikasi Masalah

Langkah pertama dalam penelitian ini adalah mengidentifikasi masalah. Pada tahap ini, dilakukan pemilihan topik, perumusan masalah, dan penetapan tujuan penelitian. Tujuan dari langkah ini adalah untuk memastikan arah penelitian yang jelas dan relevan, memberikan pemahaman mendalam mengenai isu yang ingin diteliti, serta menyusun panduan untuk keseluruhan proses penelitian. Identifikasi masalah dalam penelitian ini diawali dengan observasi terhadap rendahnya akurasi dan lamanya waktu yang dibutuhkan dalam prediksi kepribadian. Hal ini disebabkan oleh metode prediksi kepribadian yang masih menggunakan pendekatan tradisional, seperti pengisian kuesioner.

3.1.2. Studi Literatur

Tahap berikutnya adalah studi literatur, di mana peneliti mencari referensi dan literatur yang berhubungan dengan topik penelitian, termasuk buku, jurnal, artikel, dan sumber online lainnya. Langkah ini bertujuan untuk memahami konsep teori, metodologi penelitian, serta temuan-temuan yang relevan terkait subjek penelitian, penerapan teknologi deep learning dalam prediksi kepribadian, dan penggunaan model transfer learning.

3.2. Tahap Pengembangan Model dan Website


Tahap kedua adalah pengembangan model dan pengembangan website. Langkah-langkah dalam tahap ini mengacu pada pendekatan metodologi CRISP-DM dalam proses pengolahan data serta pembuatan solusi. Setelah model dikembangkan menggunakan bahasa pemrograman Python, sistem informasi website akan dibangun dengan menggunakan framework Flask. Model yang telah dibuat akan disimpan dan

diintegrasikan ke dalam framework tersebut. Tahap ini mencakup beberapa langkah sebagai berikut:

3.2.1 Pengumpulan Data

Pengumpulan data dalam penelitian ini dilakukan dengan menggunakan data sekunder yang diambil dari dataset ChaLearn Looking at People (LAP), yang digunakan dalam kompetisi di CVPR 2017 dan terdiri dari sekitar 6.000 video. Video-video tersebut diambil dari berbagai konteks sosial dan dilengkapi dengan anotasi kepribadian untuk setiap individu yang tampil dalam video.

3.2.2 Persiapan Data



Gambar 3.2 Diagram Alur Persiapan Data

Proses persiapan data adalah tahap yang dilakukan setelah pengumpulan data untuk mempersiapkannya agar dapat diproses menggunakan model yang telah ditentukan. Proses ini terdiri dari tiga langkah, yaitu:

- 1) Cleaning data, di mana gambar yang telah dikumpulkan disesuaikan dengan melakukan pemotongan latar belakang, peningkatan kontras, penyesuaian warna, atau untuk meningkatkan ketajaman detail.
- 2) Augmentasi data, yaitu penambahan variasi pada dataset pelatihan yang dihasilkan melalui transformasi seperti

rotasi, pergeseran, shear, zoom, dan flip horizontal pada gambar.

- 3) Anotasi, yang merupakan tahap pemberian label atau informasi lainnya pada objek atau area tertentu dalam gambar. Keseluruhan proses preprocessing ini merupakan langkah penting dalam mempersiapkan dataset untuk pelatihan model.

3.2.3 Pembangunan Model



Gambar 3.3 Diagram Alur Pengembangan Model

Pembangunan model dalam penelitian ini dilakukan menggunakan Google Colab, dengan tahapan sebagai berikut:

- 1) Dimulai dengan pengolahan gambar menggunakan OpenCV untuk mendeteksi objek dalam gambar.
- 2) Melakukan deteksi wajah pada gambar dengan menggunakan MTCNN.
- 3) Memilih model DeepID yang terdiri dari beberapa tahapan, yaitu pre-trained model, ekstraksi fitur model, dan fully connected layer.
- 4) Melakukan klasifikasi model menggunakan metode SVM untuk memprediksi kepribadian.
- 5) Mengoptimasi model dengan algoritma Adam Optimizer untuk melatih model dan menyesuaikan parameter seperti laju pembelajaran sesuai dengan kebutuhan.
- 6) Selanjutnya, melatih model dengan menggunakan data pelatihan yang telah disiapkan sebelumnya, serta mengatur hiperparameter seperti tingkat pembelajaran, jumlah epoch, dan ukuran batch. Setelah itu, model akan disimpan dan diintegrasikan ke dalam framework Flask.

3.2.4 Evaluasi

Setelah semua tahap dilatih, evaluasi kinerja model dilakukan untuk memastikan efektivitasnya dalam mendeteksi objek di berbagai kondisi gambar. Dalam penelitian ini, evaluasi dilakukan menggunakan metode Confusion Matrix dengan beberapa rumus berikut:

- 1) Accuracy, yang menunjukkan seberapa akurat model dapat mengklasifikasikan dengan benar.

$$accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (3.1)$$

- 2) Precision (Positive Predictive Value), yang menggambarkan tingkat keakuratan antara data yang diminta dan hasil prediksi yang diberikan oleh model.

$$precision = \frac{TP}{TP+FP} \quad (3.2)$$

- 3) Recall atau Sensitivity (True Positive Rate), yang menunjukkan keberhasilan model dalam mengidentifikasi informasi yang relevan.

$$recall = \frac{TP}{TP+FN} \quad (3.3)$$

- 4) F1 Score, yang mencerminkan keseimbangan antara Precision dan Recall, memberikan informasi tentang seberapa baik model yang telah dikembangkan.

$$F1\ Score = 2 \times \frac{recall \times precision}{recall + precision} \quad (3.4)$$

3.2.5 Desain Sistem

Pada tahap ini, dilakukan perancangan sistem untuk menjadi landasan penting dalam membangun sistem, dalam tahap ini dapat digambarkan, seperti berikut :

1. Analisis Kebutuhan

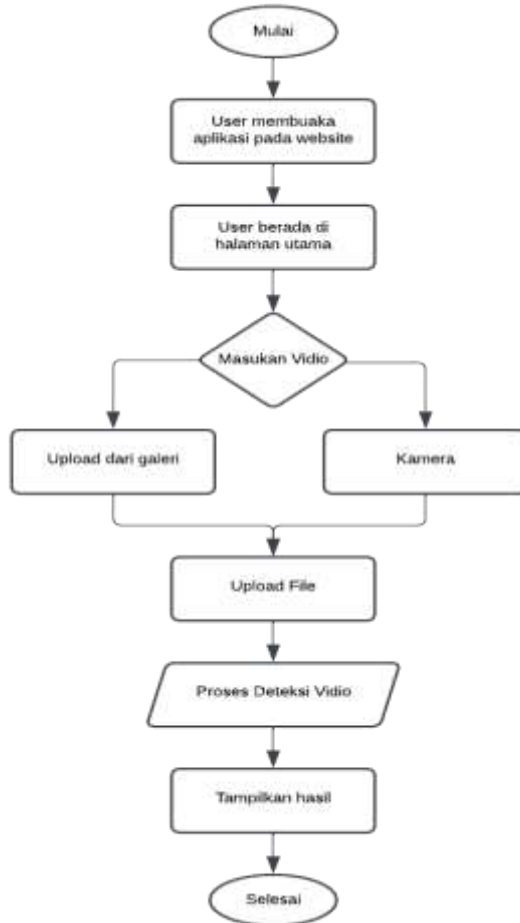
Dimulai dengan analisis kebutuhan perangkat keras dan perangkat lunak untuk mengembangkan sistem dan model. Dimana dari sisi perangkat keras memerlukan CPU Intel Core i7 atau AMD Ryzen 7 dengan 8 core, GPU NVIDIA RTX 3060 12 GB VRAM, RAM 32GB, SSD 1TB. Sementara untuk perangkat lunak menggunakan Visual Studio Code atau Google Colab, serta bahasa pemrograman dan library, seperti Python, TensorFlow, dan framework Flask.

2. Analisis Input dan Output

Selanjutnya dilakukan analisis input output untuk menentukan jenis data yang akan diterima dan dikeluarkan oleh sistem. Sistem ini dirancang untuk menerima input berupa video, yang kemudian akan diproses untuk menghasilkan output yang merupakan hasil prediksi kepribadian pengguna.

3. Perancangan Alur Kerja Sistem

Berikut rancangan desain alur kerja yang digunakan sebagai acuan pengembangan aplikasi website :



Gambar 3. 4 Diagram Alur Kerja Sistem

4. Desain Gambar Kerangka

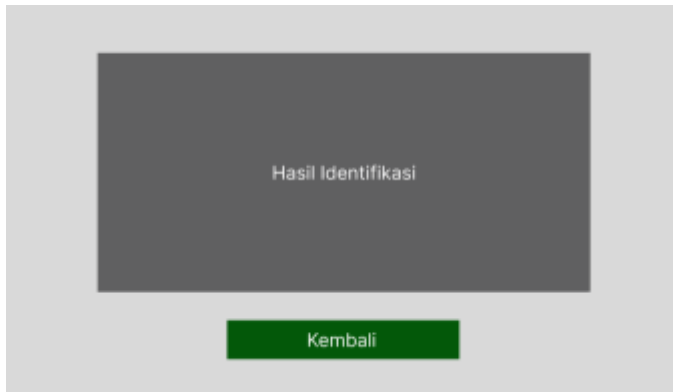
Berikut rancangan desain alur kerja yang digunakan sebagai acuan pengembangan aplikasi website :



Gambar 3.5 Halaman Utama



Gambar 3.6 Halaman Preview Gambar



Gambar 3.7 Hasil Identifikasi Kepribadian

3.2.6 Penerapan Sistem

Tahap ini adalah implementasi sistem berdasarkan desain yang telah disusun sebelumnya, yang mencakup proses penulisan kode aplikasi mobile menggunakan framework Flask. Aplikasi ini dirancang agar pengguna dapat melakukan input, setelah itu video akan dianalisis menggunakan model yang telah disimpan, dan hasil analisis beserta prediksi kepribadian akan ditampilkan.

3.2.7 Pengujian Sistem

Setelah implementasi selesai, sistem akan diuji untuk memastikan bahwa semua fitur berfungsi dengan baik dan sesuai dengan desain sistem yang telah dibuat.

3.3. Tahap Pelaporan

Tahap akhir dari penelitian ini adalah penyusunan laporan. Setelah tahap pengembangan aplikasi selesai, langkah terakhir adalah tahap III, yaitu pelaporan, dimana hasil penelitian dan implementasi sistem akan disusun dalam bentuk laporan yang lengkap dan terstruktur. Laporan ini disiapkan untuk keperluan dokumentasi dan publikasi.

DAFTAR PUSTAKA

- Suman, C., Saha, S., Gupta, A., Pandey, S. K., & Bhattacharyya, P. (2022). A multi-modal personality prediction system. In *Knowledge-Based Systems* (Vol. 236).
<https://doi.org/10.1016/j.knosys.2021.107715>
- Mehta, Y., Majumder, N., Gelbukh, A., & Cambria, E. (2020). Recent trends in deep learning based personality detection. *Artificial Intelligence Review*, 53(4), 2313–2339.
<https://doi.org/10.1007/s10462-019-09770-z>
- Alshouha, B., Guerrero, J. S., Chiclana, F., Romero, F. P., & Olivas, J. A. (2024). Personality trait detection via transfer learning. *Computers, Materials and Continua*, 78(2), 1933–1956.
<https://doi.org/10.32604/cmc.2023.046711>
- Beedu, G. K. (2021). A Study on the Effectiveness of DISC Personality Test. 101.
- Ryan, G., Katarina, P., & Suhartono, D. (2023). MBTI Personality Prediction Using Machine Learning and SMOTE for
- Tinwala, W., & Rauniyar, S. (2021). Big Five Personality Detection Using Deep Convolutional Neural Networks.
<https://doi.org/10.20944/preprints202109.0199.v1>
- Nagaraja, G. S., & Revathi, S. (2023). Multimodal Personality Prediction Using Deep Learning Techniques. *7th IEEE International Conference on Computational Systems and Information Technology for Sustainable Solutions, CSITSS 2023 - Proceedings, November 2023*, 1–7.
<https://doi.org/10.1109/CSITSS60515.2023.10334177>
- Kachur, A., Osin, E., Davydov, D., Shutilov, K., & Novokshonov, A. (2020). Assessing the Big Five personality traits using real-life static facial images. *Scientific Reports*, 10(1), 8487.
<https://doi.org/10.1038/s41598-020-65358-6>

- L. W. Alexander and S. Sentinuwo. (2017). Implementasi Algoritma Pengenalan Wajah Untuk Mendeteksi Visual Hacking, *J. Tek. Inform.*, (Vol. 11).
<https://doi.org/10.46764/teknimedia.v4i1.92>
- R. Wiryadinata, R. Sagita, S. Wardoyo, and P. Priswanto. (2016). Pengenalan Wajah Pada Sistem Presensi Menggunakan Metode Dynamic Times Wrapping, Principal Component Analysis Dan Gabor Wavelet, *Din. Rekayasa*, (Vol. 12).
<http://dx.doi.org/10.20884/1.dr.2016.12.1.138>
- M. Chihaoui, A. Elkefi, W. Bellil, and C. Ben Amar. (2016). A survey of 2D face recognition techniques, *Computers*, (Vol. 5). <https://doi.org/10.3390/computers5040021>
- Heidari, S., Dinneen, M. J., & Delmas, P. (2024). Quantum Annealing for Computer Vision minimization problems. *Future Generation Computer Systems*, 160(December 2023), 54–64. <https://doi.org/10.1016/j.future.2024.05.037>
- Intel. (2024.). *Computer Vision Overview*. Retrieved October 26, 2024, from
<https://www.intel.co.id/content/www/id/id/internet-of-things/computer-vision/overview.html>
- Szeliski, R. (2022). *Computer Vision: Algorithms and Applications Second Edition*. Dalam *Computer Vision: Algorithms and Applications Second Edition* (hlm. 1–26). Springer International Publishing.
https://doi.org/10.1007/978-3-030-34372-9_1
- Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning. *Electronic Markets*, 31(3), 685–695.
<https://doi.org/10.1007/s12525-021-00475-2>
- Li, Z., Liu, F., Yang, W., Peng, S., & Zhou, J. (2022). A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects. *IEEE Transactions on Neural Networks and*

- Learning Systems, 33(12), 6999–7019.
<https://doi.org/10.1109/TNNLS.2021.3084827>
- Kiranyaz, S., Avci, O., Abdeljaber, O., Ince, T., Gabbouj, M., & Inman, D. J. (2021). 1D convolutional neural networks and applications: A survey. *Mechanical Systems and Signal Processing*, 151, 107398.
<https://doi.org/10.1016/j.ymssp.2020.107398>
- K. O'Shea and R. Nash. (2015). An Introduction to Convolutional Neural Networks. <http://arxiv.org/abs/1511.08458>
- K. Parthy. (2018). CS231n Convolutional Neural Networks for Visual Recognition, Stanford University Course cs231n. <http://cs231n.github.io/neural-networks-3/>.
- I. Putra. (2016). Klasifikasi Citra Menggunakan Convolutional Neural Network (CNN) pada Caltech 101. Institut Teknologi Sepuluh Nopember.
<http://dx.doi.org/10.12962/j23373539.v5i1.15696>
- Shubham Mishra, Mrs. Versha Verma, Dr. Nikhat Akhtar, Shivam Chaturvedi, & Dr. Yusuf Perwej. (2022). An Intelligent Motion Detection Using OpenCV. *International Journal of Scientific Research in Science, Engineering and Technology*, 51–63. <https://doi.org/10.32628/IJSRSET22925>
- Ralev, I., & Krastev, G. (2022). Components and model of implementation of a hand gesture recognition system. 2022 International Congress on Human-Computer Interaction, 42 Optimization and Robotic Applications (HORA), 1–4.
<https://doi.org/10.1109/HORA55278.2022.9799919>
- Ku, H. & Dong, Wei. (2020). Face Recognition Based on MTCNN and Convolutional Neural Network. *Frontiers in Signal Processing*, 4(1). <https://doi.org/10.22606/fsp.2020.41006>
- Y. Sun, X. Wang, and X. Tang. (2014). Deep learning face representation from predicting 10,000 classes, in *Proceedings of the IEEE conference on computer vision and*

- pattern recognition.
<https://doi.org/10.1109/CVPR.2014.244>
- Sheth, V., Tripathi, U., & Sharma, A. (2022). A Comparative Analysis of Machine Learning Algorithms for Classification Purpose. *Procedia Computer Science*, 215, 422– 431.
<https://doi.org/10.1016/j.procs.2022.12.044>
- Dania Siregar, Faroh Ladayya, Naufal Zhafran Albaqi, & Bintang Mahesa Wardana. (2023). Penerapan Metode Support Vector Machines (SVM) dan Metode Naïve Bayes Classifier (NBC) dalam Analisis Sentimen Publik terhadap Konsep Child-free di Media Sosial Twitter. *Jurnal Statistika dan Aplikasinya*, 7(1), 93–104.
<https://doi.org/10.21009/JSA.07109>
- Reyad, M., Sarhan, A. M., & Arafa, M. (2023). A modified Adam algorithm for deep neural network optimization. *Neural Computing and Applications*, 35(23), 17095–17112.
<https://doi.org/10.1007/s00521-023-08568-z>
- Krüger, Frank. (2016). Activity, Context, and Plan Recognition with Computational Causal Behaviour Models.
https://www.researchgate.net/publication/314116591_Activity_Context_and_Plan_Recognition_with_Computational_Causal_Behaviour_Models
- TensorFlow. (2024.). *Keras API Components*.
https://www.tensorflow.org/guide/keras#keras_api_components
- Joshi, D., Anwarul, S., & Mishra, V. (2020). Deep Learning Using Keras: Dalam M. Mahrishi, K. K. Hiran, G. Meena, & P. Sharma (Ed.), *Advances in Computer and Electrical Engineering* (hlm. 33–60). IGI Global.
<https://doi.org/10.4018/978-1-7998-3095-5.ch002>
- Maulid, R. (2021, Januari 9). Mengenal Flask, Library Machine Learning Python Idaman Developer. DQLab.
<https://dqlab.id/mengenal-flask-library-machinelearning->

[python-idaman-developer](#)

Ding, B., Yao, F., Wu, Y., & He, Y. (2012). Improving Flask Implementation Using Hardware Assisted In-VM Isolation. Dalam D. Gritzalis, S. Furnell, & M. Theoharidou (Ed.), Information Security and Privacy Research (Vol. 376, hlm. 115–125). Springer Berlin Heidelberg.
https://doi.org/10.1007/978-3-642-30436-1_10

Hotz, N. (2024). *What is CRISP DM?* Data Science Process Alliance. <https://www.datascience-pm.com/crisp-dm-2/>

Brzozowska, J., Pizoń, J., Baytikenova, G., Gola, A., Zakimova, A., & Piotrowska, K. (2023). Data Engineering in Crisp-Dm Process Production Data – Case Study. *Applied Computer Science*, 19(3), 83–95. <https://doi.org/10.35784/acs-2023-26>

Sun, Q., & Redei, A. (2022). Knock Knock, Who's There: Facial Recognition using CNN-based Classifiers. *International Journal of Advanced Computer Science and Applications*, 13(1). <https://doi.org/10.14569/IJACSA.2022.0130102>